# TransReID kết hợp Visibility-Guided Patch Weighting

Nguyễn Lê Trúc Mai
MSSV: 23127224
Khoa Công nghệ thông tin
Trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM
Thành phố Hồ Chí Minh, Việt Nam
nltmai23@clc.fitus.edu.vn

Trần Gia Huy
MSSV: 23127199
Khoa Công nghệ thông tin
Trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM
Thành phố Hồ Chí Minh, Việt Nam
tghuy23@clc.fitus.edu.vn

*Tóm tắt nội dung*—Bài báo tập trung nghiên cứu bài toán *Person Re-identification* (ReID) trên nền tảng TransReID, với mục tiêu cải thiện chất lượng truy hồi trong các bối cảnh có thay đổi lớn về góc nhìn, tư thế và che khuất. Nghiên cứu đề xuất hai hướng bổ sung ở mức patch token: semantic alignment dựa trên human parsing và local reliability để đánh giá độ tin cậy của token cục bộ. Semantic alignment được dùng như tín hiệu giám sát trong huấn luyện, không cần semantic mask ở pha suy luận; local reliability chỉ hiệu chỉnh đặc trưng với hệ số nhỏ để bảo toàn vai trò của global branch. Trong thiết lập so sánh công bằng từ khởi tạo ImageNet trên Market-1501, bản kết hợp semantic alignment và local reliability đạt 90.1% mAP và 95.4% Rank-1, cao hơn baseline TransReID lần lượt 0.9 và 0.3 điểm phần trăm, với độ trễ tăng khoảng 3.4%. Repo: https://github.com/TrucmaiUS/K23-TGMT

*Từ khóa*—person re-identification, transformer, TransReID, semantic alignment, local reliability, metric learning

## I. Giới thiệu

### A. Bối cảnh bài toán

Cùng với sự phát triển của các hệ thống giám sát thông minh, bài toán nhận dạng con người qua nhiều camera ngày càng nhận được nhiều sự quan tâm trong lĩnh vực thị giác máy tính. Trong các môi trường như sân bay, nhà ga, trung tâm thương mại hay khu vực công cộng, một người có thể xuất hiện ở nhiều camera khác nhau với các điều kiện quan sát không đồng nhất. Do đó, việc xác định các hình ảnh thu được từ nhiều camera có thuộc cùng một người hay không là một bài toán có ý nghĩa thực tiễn cao.

Bài toán này là **Person Re-identification (Person ReID)**. Mục tiêu của Person ReID là tìm kiếm hoặc xác định lại một người trong tập ảnh hoặc video được thu thập từ nhiều camera khác nhau. Đây là một hướng nghiên cứu quan trọng, có nhiều ứng dụng trong giám sát an ninh, phân tích hành vi và quản lý di chuyển trong không gian công cộng.

Tuy nhiên, Person ReID là một bài toán khó do sự thay đổi lớn về góc nhìn, ánh sáng, tư thế, độ phân giải ảnh và hiện tượng che khuất giữa các camera. Cạnh đó, sự tương đồng về trang phục hoặc ngoại hình giữa nhiều người khác nhau cũng làm gia tăng khả năng nhầm lẫn.

### B. Vấn đề nghiên cứu

Trong những năm gần đây, các phương pháp học sâu đã cho thấy hiệu quả nổi bật trong bài toán Person ReID nhờ khả năng học đặc trưng trực tiếp từ dữ liệu. Nhưng hiệu quả của mô hình vẫn chịu ảnh hưởng bởi sự đa dạng của dữ liệu, khả năng biểu diễn đặc trưng và cách đo lường độ tương đồng giữa các đối tượng.

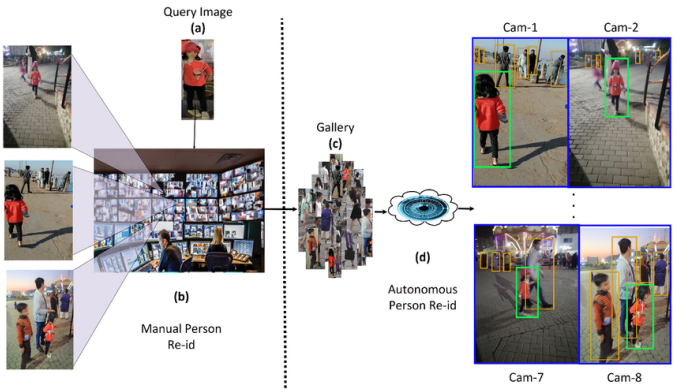


Hình 1. Minh họa bài toán Person Re-identification trong hệ thống giám sát nhiều camera.

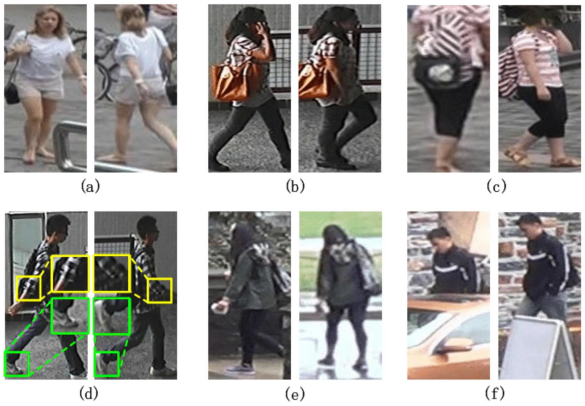


Hình 2. Một số thách thức chính trong bài toán Person Re-identification, bao gồm thay đổi góc nhìn, tư thế, che khuất và nền nhiễu.

Từ đó, đề tài đặt ra các vấn đề chính cần xem xét: các hướng tiếp cận hiện có giải quyết bài toán, mô hình phù hợp để áp dụng trong phạm vi đồ án, và những cải tiến giúp nâng cao hiệu quả nhận dạng khi thực nghiệm trên tập dữ liệu chuẩn.

## II. Các công trình liên quan

### A. Phạm vi khảo sát

Tập trung tổng hợp các hướng tiếp cận tiêu biểu trong Person ReID theo các nhóm phương pháp chính. Khảo sát được tổ chức theo kiến trúc mô hình, cơ chế học đặc trưng và định hướng cải tiến, từ đó làm rõ ưu điểm, hạn chế và khoảng trống nghiên cứu để định vị hướng đề xuất của đề tài.

### B. Nhóm phương pháp theo bộ phận cơ thể

Các phương pháp theo bộ phận cơ thể chia ảnh người thành nhiều vùng theo chiều dọc để học đặc trưng cục bộ. Hướng này giúp mô hình tập trung vào các chi tiết phân biệt như áo, quần, ba lô hoặc giày.

**Beyond Part Models: Person Retrieval with Refined Part Pooling (and a Strong Convolutional Baseline)** [1], tác giả đề xuất biểu diễn người bằng nhiều vector đặc trưng theo từng phần cơ thể, sau đó tinh chỉnh quá trình gộp đặc trưng để tăng tính ổn định. Một hướng mở rộng quan trọng là kết hợp Part-based Convolutional Baseline/Refined Part Pooling với metric learning bên cạnh phân loại ID bằng Softmax, giúp cải thiện chất lượng truy hồi trong các trường hợp mẫu âm khó.

**Learning Diverse Features with Part-Level Resolution for Person Re-Identification** [2] cho thấy việc học đa dạng đặc trưng ở các phần cơ thể có thể tăng độ bền vững khi một số vùng bị nhiễu hoặc che khuất.

### C. Nhóm CNN đa nhánh và đa tỉ lệ

Nhóm này khai thác thông tin ở nhiều mức hạt khác nhau để cân bằng giữa đặc trưng toàn cục và cục bộ. **Learning Discriminative Features with Multiple Granularities for Person Re-Identification** [3] sử dụng nhiều nhánh song song để trích xuất đặc trưng ở các độ phân giải khác nhau, nhờ đó tăng độ phân biệt cho bài toán xếp hạng.

**Omni-Scale Feature Learning for Person Re-identification** [4] tập trung vào khả năng học đặc trưng ở nhiều vùng thụ cảm trong cùng một khối mạng, giúp mô hình thích nghi tốt với biến thiên kích thước và bối cảnh.

### D. Nhóm semantic alignment và Transformer

Nhóm này tập trung vào việc học quan hệ ngữ nghĩa giữa các vùng cơ thể và tăng khả năng mô hình hóa phụ thuộc dài hạn. Nhờ đó, mô hình có thể giảm sai lệch do thay đổi tư thế, góc nhìn và tình trạng thiếu thông tin ở một số vùng ảnh.

**Densely Semantically Aligned Person Re-Identification** [5], tác giả đưa thông tin ngữ nghĩa vào quá trình căn chỉnh đặc trưng để giảm sai lệch do tư thế và góc nhìn. Hướng này đặc biệt hữu ích khi các phần cơ thể xuất hiện không đầy đủ giữa các camera.

**TransReID: Transformer-based Object Re-Identification** [6] mở rộng hướng tiếp cận Transformer cho ReID, cho phép mô hình học quan hệ dài hạn giữa các vùng ảnh tốt hơn CNN truyền thống. Tuy nhiên, các mô hình Transformer thường yêu cầu tài nguyên huấn luyện lớn hơn và cần tinh chỉnh cẩn thận trên dữ liệu mục tiêu.

### E. Hướng kết hợp vision-language và tự giám sát

Hướng tiếp cận này tận dụng tín hiệu ngữ nghĩa và cơ chế học không cần gán nhãn đầy đủ để bổ sung cho đặc trưng thị giác truyền thống. Mục tiêu là tăng độ bền vững của mô hình trong các tình huống khó như che khuất, thay đổi ngoại hình hoặc khác biệt bối cảnh giữa các camera.

**Beyond Appearance: a Semantic Controllable Self-Supervised Learning Framework for Human-Centric Visual Tasks** [7] cho thấy tiềm năng của việc dùng tín hiệu ngữ nghĩa để bổ sung cho đặc trưng ngoại hình thuần túy. Đây là hướng phù hợp để xử lý các trường hợp che khuất hoặc trang phục tương tự, khi chỉ dựa trên đặc trưng ngoại hình dễ gây nhầm lẫn.

### F. Khoảng trống nghiên cứu và định hướng đề tài

Từ các nghiên cứu trên có thể rút ra ba nhận xét chính. Thứ nhất, các mô hình theo bộ phận cơ thể có tính phân biệt tốt, nhưng vẫn nhạy với sai lệch căn chỉnh và hiện tượng che khuất mạnh. Thứ hai, các mô hình CNN đa tỉ lệ hoặc Transformer cải thiện đáng kể chất lượng biểu diễn đặc trưng, song chi phí tính toán thường cao hơn khi triển khai trong thực tế. Thứ ba, việc tích hợp đồng thời đặc trưng ngoại hình, tín hiệu ngữ nghĩa và metric learning vẫn là một hướng tiếp cận giàu tiềm năng để tiếp tục nâng cao hiệu quả nhận dạng.

Từ đó, đề tài lựa chọn **TransReID** [6] làm mô hình nền và đề xuất mở rộng theo hai hướng bổ sung: **semantic alignment** và **local reliability**. Semantic alignment khai thác human parsing mask như tín hiệu giám sát ở mức patch token, trong khi local reliability học độ tin cậy của token cục bộ để hiệu chỉnh đặc trưng một cách bảo thủ. Phần này sẽ được trình bày chi tiết ở mục Phương pháp đề xuất.

## III. Phương pháp đề xuất

Nghiên cứu xây dựng các biến thể cải tiến trên nền tảng **TransReID** [6]. Phiên bản hiện tại giữ nguyên vai trò trung tâm của global branch và JPM branch của TransReID. Các thành phần mới được đưa vào như tín hiệu giám sát phụ hoặc hiệu chỉnh cục bộ có hệ số nhỏ, nhằm bổ sung thông tin cho biểu diễn token mà không làm thay đổi pipeline truy hồi chính.

Ba biến thể được khảo sát gồm: **semantic alignment**, **local reliability**, và **semantic alignment kết hợp local reliability**. Các kiến trúc tương ứng được trình bày trong Hình 3.

### A. Baseline TransReID

Với ảnh đầu vào $x$, TransReID chia ảnh thành các patch và đưa chuỗi token qua backbone Transformer. Gọi $Z = [z_1, z_2, \ldots, z_N]$, $z_i \in \mathbb{R}^d$, là tập patch token sau backbone. Nhánh toàn cục sử dụng CLS token để tạo đặc trưng $f_g$, trong khi JPM branch thực hiện shuffle và chia nhóm patch token để tạo các đặc trưng cục bộ. Đặc trưng truy hồi cuối cùng được xây dựng từ global branch và JPM branch theo pipeline gốc của TransReID.

Hàm mất mát baseline gồm ID classification loss và triplet loss:

$$\mathcal{L}_{base} = \mathcal{L}_{ID}^{JPM} + \mathcal{L}_{tri}^{JPM}.$$

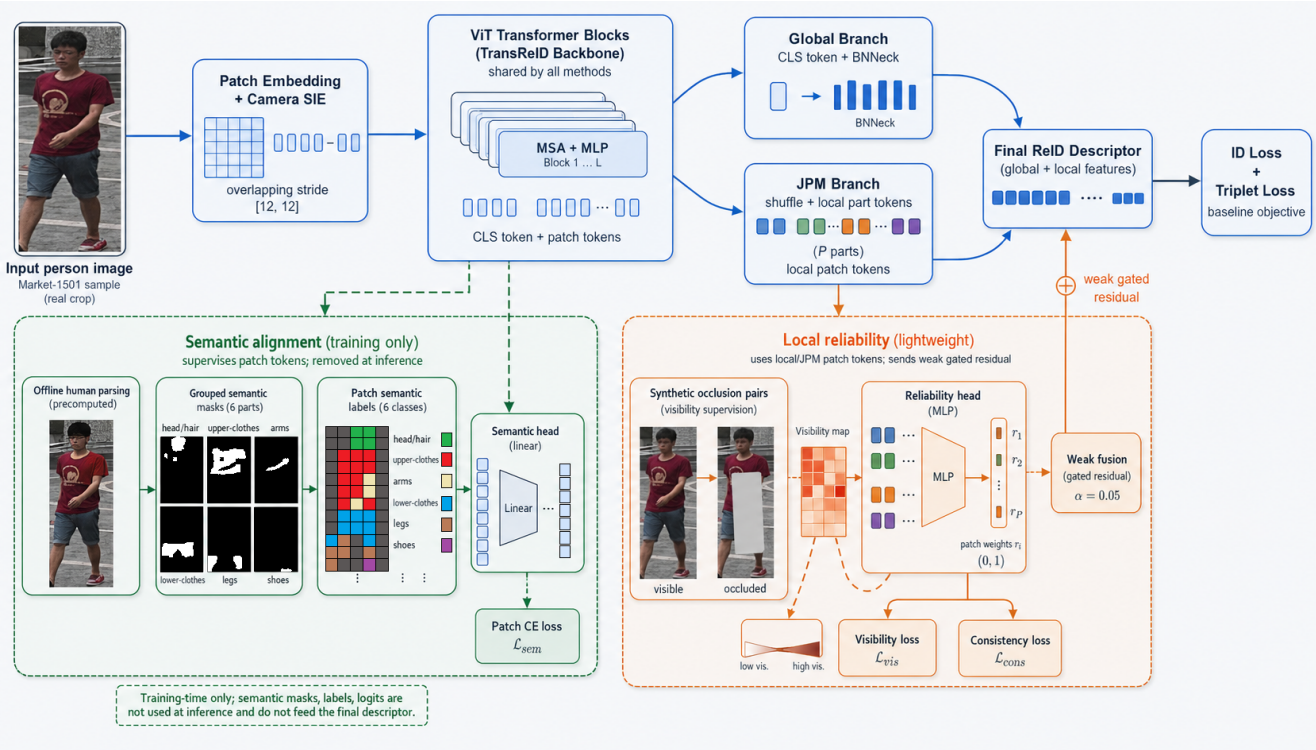


Hình 3. Kiến trúc tổng hợp của các biến thể cải tiến trên TransReID.

Tất cả các biến thể cải tiến đều kế thừa pipeline này để bảo đảm so sánh công bằng và hạn chế nhiễu từ thay đổi kiến trúc nền.

### *B. Semantic alignment*

Biến thể semantic alignment lấy cảm hứng từ Densely Semantically Aligned Person Re-Identification [5], nhưng được điều chỉnh để phù hợp với không gian token của Transformer. Thay vì xây dựng một semantic guiding stream riêng, phương pháp chỉ dùng semantic mask như tín hiệu giám sát phụ trong huấn luyện. Mục tiêu là ép patch token giữ được thông tin tương ứng với vùng cơ thể mà patch đó quan sát, trong khi đặc trưng truy hồi chính vẫn đến từ TransReID.

Trước huấn luyện, mỗi ảnh được xử lý bởi mô hình human parsing để tạo semantic mask offline. Các nhãn parsing được gộp thành $K = 6$ nhóm semantic ổn định, sau đó được đưa qua cùng các phép biến đổi hình học với ảnh đầu vào. Mask sau biến đổi được resize về lưới patch của Transformer để tạo nhãn semantic $y_i^{sem}$ cho từng patch token $z_i$. Một projection head nhẹ $h_{sem}$ dự đoán phân phối semantic của patch:

$$p_i^{sem} = h_{sem}(z_i).$$

Loss semantic được tính bằng cross-entropy trên các patch hợp lệ:

$$\mathcal{L}_{sem} = \lambda_{patch} \frac{1}{|\Omega|} \sum_{i \in \Omega} \mathrm{CE}(p_i^{sem}, y_i^{sem}),$$

trong đó $\Omega$ là tập patch có nhãn semantic hợp lệ và $\lambda_{patch}$ điều khiển mức đóng góp của nhánh phụ. Trong cấu hình báo cáo, $\lambda_{patch} = 0.2$ và semantic loss được warm-up trong 20 epoch. Đáng chú ý, semantic head chỉ phục vụ huấn luyện; ở pha suy luận mô hình không cần semantic mask và không dùng semantic logits làm đầu vào truy hồi.

### *C. Local reliability*

Biến thể local reliability tập trung vào độ tin cậy của token cục bộ. Với mỗi patch token $z_i$, một head nhẹ dự đoán hệ số tin cậy:

$$r_i = \sigma(h_{rel}(z_i)),$$

trong đó $r_i \in (0, 1)$. Các hệ số này được dùng để tạo một hiệu chỉnh cục bộ có trọng số từ patch token. Thay vì thay thế đặc trưng global, hiệu chỉnh này chỉ được trộn vào đặc trưng truy hồi với hệ số nhỏ:

$$f_{rel} = f_{base} + \alpha_{rel}\, \Delta f_{rel},$$

với $f_{base}$ là đặc trưng từ TransReID/JPM, $\Delta f_{rel}$ là hiệu chỉnh cục bộ sinh từ các token có độ tin cậy cao, và $\alpha_{rel} = 0.05$. Gate của nhánh reliability được khởi tạo ở giá trị $-4.0$, khiến ảnh hưởng ban đầu của nhánh phụ rất nhỏ. Cách khởi tạo này làm quá trình tối ưu ổn định hơn vì global branch vẫn chi phối biểu diễn ở giai đoạn đầu.

Để học reliability, quá trình huấn luyện sử dụng các cặp ảnh gốc và ảnh bị che khuất tổng hợp. Nhánh reliability được ràng buộc bởi visibility loss và consistency loss:

$$\mathcal{L}_{rel} = \lambda_{vis}\mathcal{L}_{vis} + \lambda_{cons}\mathcal{L}_{cons}.$$

Trong cấu hình báo cáo, $\lambda_{vis} = 0.10$, $\lambda_{cons} = 0.10$, metric loss phụ được tắt và regularization weight đặt bằng 0. Như vậy, local

reliability đóng vai trò hiệu chỉnh bảo thủ thay vì một nhánh truy hồi cạnh tranh với global branch.

### D. Kết hợp semantic alignment và local reliability

Biến thể kết hợp sử dụng cùng backbone TransReID và đồng thời kích hoạt hai cơ chế phụ trợ nêu trên. Semantic alignment cung cấp ràng buộc part-level ở không gian patch token trong huấn luyện, còn local reliability học cách đánh giá token cục bộ đáng tin cậy và hiệu chỉnh đặc trưng truy hồi với hệ số nhỏ. Hai thành phần này bổ sung cho nhau: semantic supervision giúp token giữ cấu trúc cơ thể rõ hơn, trong khi reliability fusion giúp giảm ảnh hưởng của vùng nhiễu hoặc che khuất trong đặc trưng cuối.

Hàm mất mát tổng quát của bản kết hợp là:

$$\mathcal{L} = \mathcal{L}_{base} + \mathcal{L}_{sem} + \mathcal{L}_{rel}.$$

Ở pha suy luận, semantic mask không còn được sử dụng. Đường suy luận chỉ gồm backbone TransReID, JPM branch và nhánh reliability đã học. Do đó, chi phí suy luận của semantic alignment đơn lẻ gần như không đổi so với baseline, còn bản kết hợp chỉ tăng thêm chi phí của reliability head nhẹ.

## IV. Thiết lập thực nghiệm

### A. Chỉ số đánh giá

Các kết quả được báo cáo trên benchmark **Market-1501** [8] theo giao thức query–gallery chuẩn của Person ReID. Hiệu năng truy hồi được đo bằng mean Average Precision (mAP) và Cumulative Matching Characteristics (CMC) tại Rank-1, Rank-5 và Rank-10. Ngoài ra, độ trễ suy luận được đo để so sánh tốc độ inference giữa các biến thể.

### B. Các phương pháp so sánh

Thực nghiệm so sánh bốn mô hình: TransReID baseline, TransReID với semantic alignment, TransReID với local reliability, và bản kết hợp semantic alignment với local reliability. Tất cả mô hình dùng cùng backbone TransReID stride với JPM và SIE camera. Các cấu hình chỉ khác nhau ở cơ chế semantic alignment và local reliability được mô tả trong Mục III.

## V. Kết quả thực nghiệm

Bảng I trình bày kết quả của bốn cấu hình trong cùng thiết lập huấn luyện từ khởi tạo ImageNet trên Market-1501. Tất cả cấu hình đều được huấn luyện $120$ epoch với batch size $64$ và learning rate $0.008$. Quá trình huấn luyện và đo độ trễ được thực hiện trên GPU NVIDIA RTX PRO 6000 Blackwell.

Hình 4 trực quan hóa hai khía cạnh chính của kết quả cuối: độ chính xác truy hồi và chi phí suy luận. Hình 5 cho thấy xu hướng hội tụ của các cấu hình qua các lần validation trong quá trình huấn luyện.

### A. Hiệu quả của semantic alignment

Semantic alignment đạt $89.5\%$ mAP và $95.3\%$ Rank-1, cao hơn baseline lần lượt $0.3$ và $0.2$ điểm phần trăm. Mức cải thiện này không lớn, nhưng có ý nghĩa vì độ trễ gần như không thay đổi: thời gian suy luận tăng từ $4.626$ ms lên $4.637$ ms, tương đương khoảng $0.23\%$. Kết quả này phù hợp với thiết kế của phương pháp, vì semantic mask chỉ được dùng để tạo patch-level supervision trong huấn luyện và không được dùng làm đầu vào ở pha suy luận.

Điểm quan trọng là semantic alignment không can thiệp trực tiếp vào global branch. Phiên bản hiện tại chỉ dùng semantic như một regularizer ở không gian patch token: patch token được khuyến khích giữ thông tin part-level trong quá trình huấn luyện, nhưng descriptor cuối vẫn được tạo bởi pipeline TransReID/JPM gốc. Cách tích hợp này giúp bổ sung tín hiệu căn chỉnh ngữ nghĩa mà không làm thay đổi đường truy hồi chính.

### B. Hiệu quả của local reliability

Local reliability đạt $89.9\%$ mAP, tăng $0.7$ điểm so với baseline, trong khi Rank-1 tăng nhẹ từ $95.1\%$ lên $95.2\%$. Mức cải thiện mAP lớn hơn semantic alignment đơn lẻ, cho thấy việc đánh giá độ tin cậy token cục bộ có ảnh hưởng rõ đến chất lượng sắp hạng tổng thể. Tuy nhiên, độ trễ tăng từ $4.626$ ms lên $4.786$ ms, tương đương khoảng $3.45\%$, do reliability head vẫn được sử dụng khi suy luận.

Việc tăng Rank-1 không nhiều nhưng mAP tăng rõ hơn cho thấy local reliability chủ yếu cải thiện thứ tự truy hồi ở toàn bộ gallery, thay vì chỉ cải thiện mẫu đứng đầu. Điều này phù hợp với mục tiêu của reliability branch: giảm đóng góp của token cục bộ kém tin cậy và ổn định hơn đặc trưng truy hồi trong các trường hợp có nhiễu hoặc che khuất cục bộ.

### C. Hiệu quả của bản kết hợp

Bản kết hợp semantic alignment và local reliability đạt kết quả tốt nhất: $90.1\%$ mAP, $95.4\%$ Rank-1, $98.6\%$ Rank-5 và $99.1\%$ Rank-10. So với baseline, mức cải thiện là $+0.9$ điểm mAP và $+0.3$ điểm Rank-1. Độ trễ trung bình là $4.783$ ms, gần như tương đương local reliability đơn lẻ và tăng khoảng $3.39\%$ so với baseline.

Kết quả này cho thấy hai tín hiệu semantic và reliability có tính bổ sung. Semantic alignment cung cấp ràng buộc part-level trong huấn luyện nhưng không làm tăng đáng kể chi phí inference. Local reliability bổ sung cơ chế chọn lọc token đáng tin cậy hơn ở pha truy hồi. Khi kết hợp, mô hình tận dụng được cả cấu trúc ngữ nghĩa của cơ thể và độ tin cậy cục bộ của patch token, trong khi vẫn giữ global branch của TransReID làm đường biểu diễn chính.

## VI. Thảo luận

Các kết quả cho thấy hướng cải tiến phù hợp nhất là giữ pipeline TransReID/JPM làm đường biểu diễn chính, còn các thành phần mới chỉ đóng vai trò phụ trợ. Semantic alignment hoạt động như một regularizer ở mức patch token trong huấn luyện, vì vậy gần như không làm tăng chi phí suy luận. Local reliability có tham gia ở pha inference, nhưng được đưa vào bằng residual yếu để hạn chế rủi ro làm lệch descriptor chính. Thiết kế này giải thích vì sao bản kết hợp có thể cải thiện mAP trong khi vẫn giữ độ trễ ở mức thấp.

Hạn chế chính của thực nghiệm hiện tại là phạm vi đánh giá còn hẹp. Kết quả mới được báo cáo đầy đủ trên Market-1501 và chưa có đánh giá đa seed. Ngoài ra, semantic alignment phụ

| Phương pháp | mAP (%) | Rank-1 (%) | Rank-5 (%) | Rank-10 (%) | Độ trễ (ms) |
|---|---|---|---|---|---|
| Baseline TransReID | 89.2 | 95.1 | 98.3 | 98.9 | 4.626 |
| Semantic alignment | 89.5 | 95.3 | 98.5 | 99.0 | 4.637 |
| Local reliability | 89.9 | 95.2 | **98.6** | **99.1** | 4.786 |
| Semantic alignment + local reliability | **90.1** | **95.4** | **98.6** | **99.1** | 4.783 |

Độ trễ được đo với batch size 1 trên GPU NVIDIA RTX PRO 6000 Blackwell.

Bảng I. Kết quả so sánh công bằng trên Market-1501.

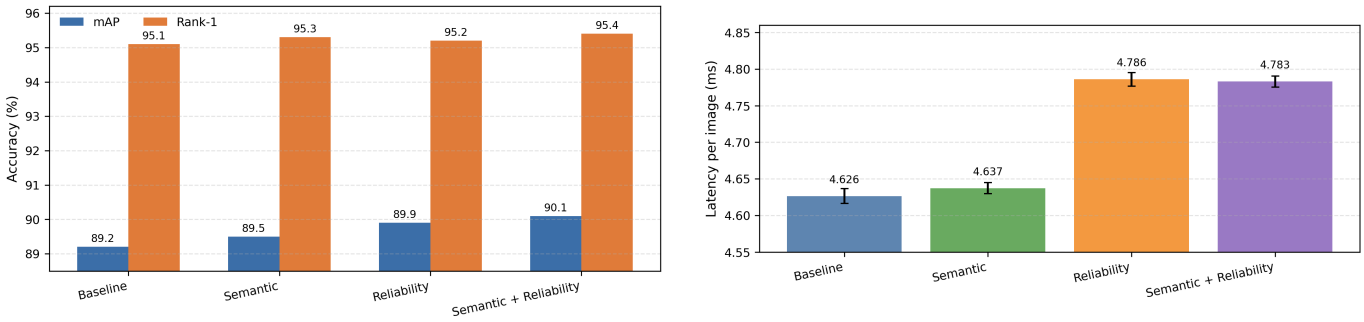


Hình 4. So sánh độ chính xác và độ trễ suy luận của các biến thể trên Market-1501.

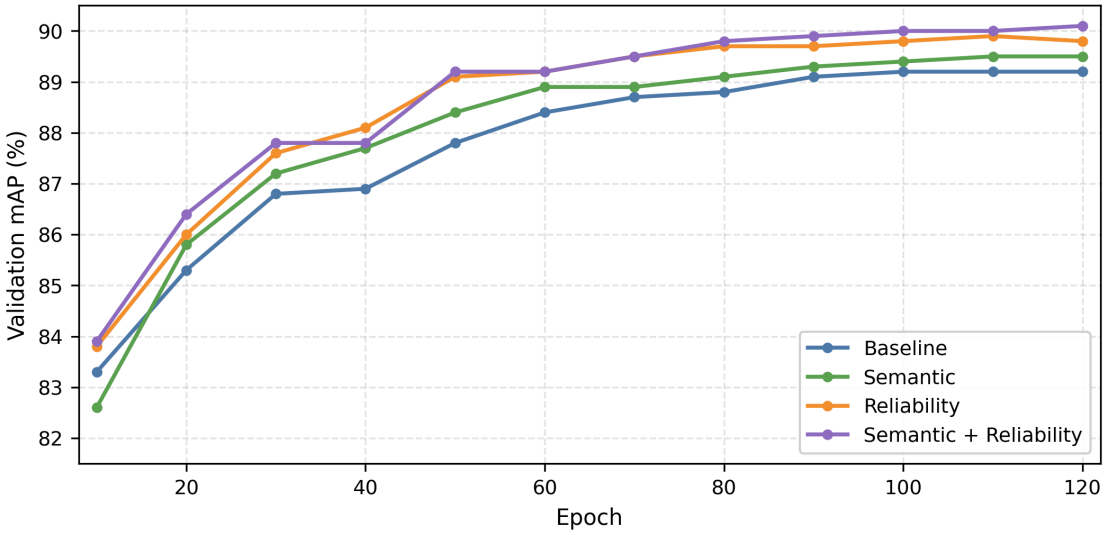


Hình 5. Diễn biến validation mAP theo epoch trong quá trình huấn luyện.

thuộc vào chất lượng parser offline, nên hiệu quả có thể thay đổi khi ảnh bị mờ, lệch bounding box hoặc che khuất mạnh. Các bước tiếp theo nên tập trung đánh giá trên Occluded-Duke, DukeMTMC-reID và kiểm tra độ ổn định của phương pháp với nhiều lần chạy độc lập.

## VII. Kết luận

Bài báo đã nghiên cứu hướng cải tiến TransReID bằng cách bổ sung thông tin ở mức patch token nhưng vẫn giữ global branch và JPM branch làm đường biểu diễn chính. Hai thành phần được khảo sát là semantic alignment và local reliability. Semantic alignment sử dụng human parsing mask như tín hiệu giám sát trong huấn luyện, giúp patch token học cấu trúc part-level mà không cần mask ở pha suy luận. Local reliability học độ tin cậy của token cục bộ và chỉ hiệu chỉnh đặc trưng cuối với hệ số nhỏ nhằm tránh làm suy yếu biểu diễn global.

Trong thiết lập so sánh công bằng trên Market-1501, semantic alignment đạt 89.5% mAP và 95.3% Rank-1, cao hơn baseline 0.3 điểm mAP với độ trễ gần như không đổi. Local reliability đạt 89.9% mAP và 95.2% Rank-1, tăng 0.7 điểm mAP nhưng làm độ trễ tăng khoảng 3.45%. Bản kết hợp semantic alignment và local reliability đạt kết quả tốt nhất với 90.1% mAP và 95.4% Rank-1, cao hơn baseline 0.9 điểm mAP và 0.3 điểm Rank-1, trong khi độ trễ vẫn dưới 5 ms mỗi ảnh trong điều kiện đo hiện tại.

Các kết quả này cho thấy semantic supervision và reliability-guided local correction là hai tín hiệu bổ sung hữu ích cho TransReID khi được tích hợp theo hướng bảo thủ. Trong tương

lai, cần đánh giá thêm trên các benchmark có che khuất nặng như Occluded-Duke, thực hiện thí nghiệm đa seed và khảo sát chất lượng semantic mask để xác định rõ hơn khả năng tổng quát hóa của phương pháp.

## TÀI LIỆU


[1] Y. Sun, L. Zheng, Y. Yang, Q. Tian, and S. Wang, "Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)," 2018. [Online]. Available: https://arxiv.org/abs/1711.09349

[2] B. Xie, X. Wu, S. Zhang, S. Zhao, and M. Li, "Learning diverse features with part-level resolution for person re-identification," 2020. [Online]. Available: https://arxiv.org/abs/2001.07442

[3] G. Wang, Y. Yuan, X. Chen, J. Li, and X. Zhou, "Learning discriminative features with multiple granularities for person re-identification," in *Proceedings of the 26th ACM international conference on Multimedia*, ser. MM '18. ACM, Oct. 2018, p. 274–282. [Online]. Available: http://dx.doi.org/10.1145/3240508.3240552

[4] K. Zhou, Y. Yang, A. Cavallaro, and T. Xiang, "Omni-scale feature learning for person re-identification," 2019. [Online]. Available: https://arxiv.org/abs/1905.00953

[5] Z. Zhang, C. Lan, W. Zeng, and Z. Chen, "Densely semantically aligned person re-identification," 2019. [Online]. Available: https://arxiv.org/abs/1812.08967

[6] S. He, H. Luo, P. Wang, F. Wang, H. Li, and W. Jiang, "Transreid: Transformer-based object re-identification," 2021. [Online]. Available: https://arxiv.org/abs/2102.04378

[7] W. Chen, X. Xu, J. Jia, H. luo, Y. Wang, F. Wang, R. Jin, and X. Sun, "Beyond appearance: a semantic controllable self-supervised learning framework for human-centric visual tasks," 2023. [Online]. Available: https://arxiv.org/abs/2303.17602

[8] L. Zheng, L. Shen, L. Tian, S. Wang, J. Wang, and Q. Tian, "Scalable person re-identification: A benchmark," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015, pp. 1116–1124. [Online]. Available: https://www.cv-foundation.org/openaccess/content_iccv_2015/papers/Zheng_Scalable_Person_Re-Identification_ICCV_2015_paper.pdf

[9] M. Gou, S. Karanam, W. Liu, O. Camps, and R. J. Radke, "Dukemtmc4reid: A large-scale multi-camera person re-identification dataset," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2017, pp. 10–19. [Online]. Available: https://openaccess.thecvf.com/content_cvpr_2017_workshops/w17/papers/Gou_DukeMTMC4ReID_A_Large-Scale_CVPR_2017_paper.pdf

## PHỤ LỤC A
## CẤU HÌNH THỰC NGHIỆM CHI TIẾT

### *A. Bộ dữ liệu và môi trường thực nghiệm*

Các kết quả định lượng trong báo cáo được đánh giá trên Market-1501 [8]. Bộ dữ liệu gồm 12,936 ảnh huấn luyện của 751 định danh, 3,368 ảnh truy vấn thuộc 750 định danh và 15,913 ảnh gallery thuộc 751 định danh, được thu thập từ 6 camera.

| **Hạng mục** | **Thiết lập** |
|---|---|
| Bộ dữ liệu | Market-1501 |
| Train / query / gallery | 12,936 / 3,368 / 15,913 ảnh |
| Số định danh huấn luyện | 751 |
| Số camera | 6 |
| GPU huấn luyện | NVIDIA RTX PRO 6000 Blackwell |
| GPU đo độ trễ | NVIDIA RTX PRO 6000 Blackwell |

Bảng II. Bộ dữ liệu và phần cứng sử dụng trong thực nghiệm.

Đối với các cấu hình bật semantic alignment, semantic mask được sinh offline bằng human parsing. Mask được đưa qua cùng các phép biến đổi hình học với ảnh đầu vào, sau đó được resize về lưới patch để tạo nhãn semantic patch-level. Baseline TransReID và local reliability không yêu cầu semantic mask.

### *B. Các cấu hình được so sánh*

### *C. Thiết lập huấn luyện chung*

### *D. Thiết lập riêng của từng cải tiến*

### *E. Đo độ trễ*

| Phương pháp | File cấu hình | Mô tả |
|---|---|---|
| Baseline TransReID | `vit_transreid_stride_fair.yml` | TransReID stride với JPM và SIE camera. |
| Semantic alignment | `vit_transreid_stride_sem_align.yml` | Thêm giám sát semantic ở mức patch token trong huấn luyện. |
| Local reliability | `vit_transreid_stride_local_reliability.yml` | Học độ tin cậy token cục bộ bằng ảnh che khuất tổng hợp và dùng residual yếu ở pha suy luận. |
| Semantic alignment + local reliability | `vit_transreid_stride_sem_align_reliability.yml` | Kết hợp giám sát semantic trong huấn luyện với hiệu chỉnh local reliability khi suy luận. |

Bảng III. Các phương pháp được so sánh trong thực nghiệm chính.

| Hạng mục | Giá trị |
|---|---|
| Backbone | ViT-B/16 TransReID stride |
| Kích thước ảnh | $256 \times 128$ |
| Stride patch | $12 \times 12$ |
| Nhánh local | JPM, có re-arrange patch token |
| Thông tin camera | SIE camera |
| Khởi tạo | ImageNet pretrained ViT-B/16 |
| Optimizer | SGD |
| Epoch | 120 |
| Batch size | 64 |
| Learning rate | 0.008 |
| Weight decay | $10^{-4}$ |
| Sampler | Softmax-triplet, 4 ảnh mỗi định danh |
| Chu kỳ đánh giá | Mỗi 10 epoch |
| Checkpoint báo cáo | Checkpoint có validation mAP tốt nhất |

Bảng IV. Thiết lập huấn luyện chung cho toàn bộ cấu hình.

| Nhóm | Thiết lập | Mục đích |
|---|---|---|
| Semantic alignment | 6 nhóm semantic từ human parsing; patch-level cross-entropy với trọng số 0.2; warm-up 20 epoch | Buộc patch token giữ thông tin part-level mà không đưa semantic mask vào descriptor suy luận. |
| Semantic alignment | Không trộn semantic logits vào global descriptor; semantic reference được tách gradient | Giữ semantic branch ở vai trò regularizer trong huấn luyện. |
| Local reliability | Reliability head ẩn 256 chiều; residual fusion với hệ số 0.05; gate khởi tạo âm mạnh | Cho phép nhánh reliability hiệu chỉnh descriptor ở mức nhỏ và ổn định. |
| Local reliability | Visibility loss và consistency loss cùng trọng số 0.10; không dùng metric loss phụ và regularization phụ | Tập trung học độ tin cậy token từ tín hiệu che khuất thay vì tạo thêm mục tiêu truy hồi cạnh tranh. |
| Local reliability | Synthetic occlusion luôn bật; vùng che chiếm khoảng 10%–28% diện tích ảnh | Tạo tín hiệu giám sát visibility cho token cục bộ. |
| Phiên bản kết hợp | Bật đồng thời semantic alignment và local reliability; pixel decoder không dùng trong cấu hình báo cáo | So sánh tác động bổ sung của hai tín hiệu semantic và reliability trong cùng backbone. |

Bảng V. Các thiết lập riêng của semantic alignment và local reliability.

| Hạng mục | Giá trị |
|---|---|
| GPU | NVIDIA RTX PRO 6000 Blackwell |
| Batch size | 1 |
| Warm-up | 30 vòng |
| Số vòng đo | 100 vòng |
| AMP | Không dùng |
| Đơn vị báo cáo | Độ trễ trung bình trên một ảnh |

Bảng VI. Thiết lập benchmark độ trễ suy luận.