TransReID kết hợp Visibility-Guided Patch Weighting

Nguyễn Lê Trúc Mai
MSSV: 23127224
Khoa Công nghệ thông tin
Trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM
Thành phố Hồ Chí Minh, Việt Nam
nltmai23@clc.fitus.edu.vn

Trần Gia Huy
MSSV: 23127199
Khoa Công nghệ thông tin
Trường Đại học Khoa học Tự nhiên - ĐHQG TP.HCM
Thành phố Hồ Chí Minh, Việt Nam
tghuy23@clc.fitus.edu.vn

Tóm tắt nội dung—Bài báo tập trung nghiên cứu bài toán *Person Re-identification* (ReID) trong lĩnh vực thị giác máy tính, với mục tiêu nhận dạng lại một người qua nhiều camera khác nhau. Trên cơ sở khảo sát các nghiên cứu liên quan, đề tài hướng đến việc đề xuất một mô hình dựa trên học sâu, thực nghiệm trên tập dữ liệu chuẩn và đánh giá hiệu quả bằng các độ đo phổ biến. Bên cạnh đó, nghiên cứu cũng xem xét một số hướng cải tiến nhằm nâng cao hiệu quả nhận dạng trong những bối cảnh có thay đổi lớn về góc nhìn, ánh sáng, tư thế và hiện tượng che khuất. Repo: https://github.com/TrucmaiUS/K23-TGMT

Từ khóa—person re-identification, computer vision, deep learning, transformer, metric learning

I. Giới thiệu

A. Bối cảnh bài toán

Cùng với sự phát triển của các hệ thống giám sát thông minh, bài toán nhận dạng con người qua nhiều camera ngày càng nhận được nhiều sự quan tâm trong lĩnh vực thị giác máy tính. Trong các môi trường như sân bay, nhà ga, trung tâm thương mại hay khu vực công cộng, một người có thể xuất hiện ở nhiều camera khác nhau với các điều kiện quan sát không đồng nhất. Do đó, việc xác định các hình ảnh thu được từ nhiều camera có thuộc cùng một người hay không là một bài toán có ý nghĩa thực tiễn cao.

Bài toán này là **Person Re-identification (Person ReID)**. Mục tiêu của Person ReID là tìm kiếm hoặc xác định lại một người trong tập ảnh hoặc video được thu thập từ nhiều camera khác nhau. Đây là một hướng nghiên cứu quan trọng, có nhiều ứng dụng trong giám sát an ninh, phân tích hành vi và quản lý di chuyển trong không gian công cộng.

Tuy nhiên, Person ReID là một bài toán khó do sự thay đổi lớn về góc nhìn, ánh sáng, tư thế, độ phân giải ảnh và hiện tượng che khuất giữa các camera. Cạnh đó, sự tương đồng về trang phục hoặc ngoại hình giữa nhiều người khác nhau cũng làm gia tăng khả năng nhầm lẫn.

B. Vấn đề nghiên cứu

Trong những năm gần đây, các phương pháp học sâu đã cho thấy hiệu quả nổi bật trong bài toán Person ReID nhờ khả năng học đặc trưng trực tiếp từ dữ liệu. Nhưng hiệu quả của mô hình vẫn chịu ảnh hưởng bởi sự đa dạng của dữ liệu, khả năng biểu diễn đặc trưng và cách đo lường độ tương đồng giữa các đối tượng.

Từ đó, đề tài đặt ra các vấn đề chính cần xem xét: các hướng tiếp cận hiện có giải quyết bài toán, mô hình phù hợp để áp dụng trong phạm vi đồ án, và những cải tiến giúp nâng cao hiệu quả nhận dạng khi thực nghiệm trên tập dữ liệu chuẩn.

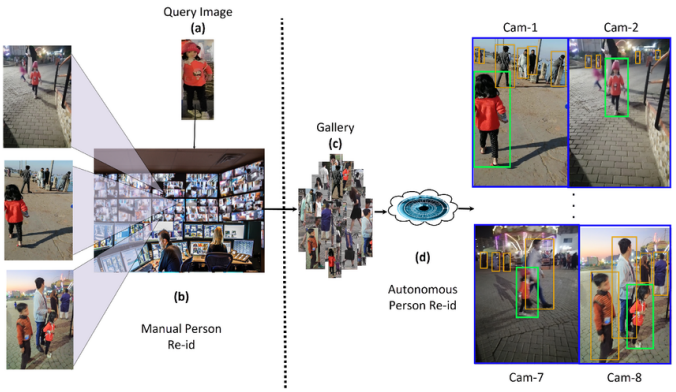

Hình 1. Minh họa bài toán Person Re-identification trong hệ thống giám sát nhiều camera.

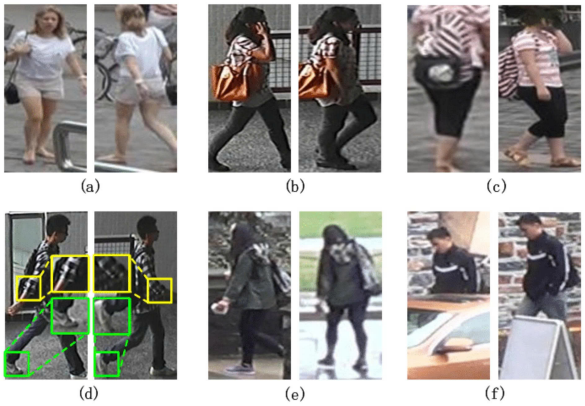

Hình 2. Một số thách thức chính trong bài toán Person Re-identification, bao gồm thay đổi góc nhìn, tư thế, che khuất và nền nhiễu.

II. Các công trình liên quan

A. Phạm vi khảo sát

Tập trung tổng hợp các hướng tiếp cận tiêu biểu trong Person ReID theo các nhóm phương pháp chính. Khảo sát được tổ chức theo kiến trúc mô hình, cơ chế học đặc trưng và định hướng cải tiến, từ đó làm rõ ưu điểm, hạn chế và khoảng trống nghiên cứu để định vị hướng đề xuất của đề tài.

B. Nhóm phương pháp theo bộ phận cơ thể

Các phương pháp theo bộ phận cơ thể chia ảnh người thành nhiều vùng theo chiều dọc để học đặc trưng cục bộ. Hướng này giúp mô hình tập trung vào các chi tiết phân biệt như áo, quần, ba lô hoặc giày.

Beyond Part Models: Person Retrieval with Refined Part Pooling (and a Strong Convolutional Baseline) [1], tác giả đề xuất biểu diễn người bằng nhiều vector đặc trưng theo từng phần cơ thể, sau đó tinh chỉnh quá trình gộp đặc trưng để tăng tính ổn định. Một hướng mở rộng quan trọng là kết hợp Part-based Convolutional Baseline/Refined Part Pooling với metric learning bên cạnh phân loại ID bằng Softmax, giúp cải thiện chất lượng truy hồi trong các trường hợp mẫu âm khó.

Learning Diverse Features with Part-Level Resolution for Person Re-Identification [2] cho thấy việc học đa dạng đặc trưng ở các phần cơ thể có thể tăng độ bền vững khi một số vùng bị nhiễu hoặc che khuất.

C. Nhóm CNN đa nhánh và đa tỉ lệ

Nhóm này khai thác thông tin ở nhiều mức hạt khác nhau để cân bằng giữa đặc trưng toàn cục và cục bộ. **Learning Discriminative Features with Multiple Granularities for Person Re-Identification** [3] sử dụng nhiều nhánh song song để trích xuất đặc trưng ở các độ phân giải khác nhau, nhờ đó tăng độ phân biệt cho bài toán xếp hạng.

Omni-Scale Feature Learning for Person Re-identification [4] tập trung vào khả năng học đặc trưng ở nhiều vùng thụ cảm trong cùng một khối mạng, giúp mô hình thích nghi tốt với biến thiên kích thước và bối cảnh.

D. Nhóm semantic alignment và Transformer

Nhóm này tập trung vào việc học quan hệ ngữ nghĩa giữa các vùng cơ thể và tăng khả năng mô hình hóa phụ thuộc dài hạn. Nhờ đó, mô hình có thể giảm sai lệch do thay đổi tư thế, góc nhìn và tình trạng thiếu thông tin ở một số vùng ảnh.

Densely Semantically Aligned Person Re-Identification [5], tác giả đưa thông tin ngữ nghĩa vào quá trình căn chỉnh đặc trưng để giảm sai lệch do tư thế và góc nhìn. Hướng này đặc biệt hữu ích khi các phần cơ thể xuất hiện không đầy đủ giữa các camera.

TransReID: Transformer-based Object Re-Identification [6] mở rộng hướng tiếp cận Transformer cho ReID, cho phép mô hình học quan hệ dài hạn giữa các vùng ảnh tốt hơn CNN truyền thống. Tuy nhiên, các mô hình Transformer thường yêu cầu tài nguyên huấn luyện lớn hơn và cần tinh chỉnh cẩn thận trên dữ liệu mục tiêu.

E. Hướng kết hợp vision-language và tự giám sát

Hướng tiếp cận này tận dụng tín hiệu ngữ nghĩa và cơ chế học không cần gán nhãn đầy đủ để bổ sung cho đặc trưng thị giác truyền thống. Mục tiêu là tăng độ bền vững của mô hình trong các tình huống khó như che khuất, thay đổi ngoại hình hoặc khác biệt bối cảnh giữa các camera.

Beyond Appearance: a Semantic Controllable Self-Supervised Learning Framework for Human-Centric Visual Tasks [7] cho thấy tiềm năng của việc dùng tín hiệu ngữ nghĩa để bổ sung cho đặc trưng ngoại hình thuần túy. Đây là hướng phù hợp để xử lý các trường hợp che khuất hoặc trang phục tương tự, khi chỉ dựa trên đặc trưng ngoại hình dễ gây nhầm lẫn.

F. Khoảng trống nghiên cứu và định hướng đề tài

Từ các nghiên cứu trên có thể rút ra ba nhận xét chính. Thứ nhất, các mô hình theo bộ phận cơ thể có tính phân biệt tốt, nhưng vẫn nhạy với sai lệch căn chỉnh và hiện tượng che khuất mạnh. Thứ hai, các mô hình CNN đa tỉ lệ hoặc Transformer cải thiện đáng kể chất lượng biểu diễn đặc trưng, song chi phí tính toán thường cao hơn khi triển khai trong thực tế. Thứ ba, việc tích hợp đồng thời đặc trưng ngoại hình, tín hiệu ngữ nghĩa và metric learning vẫn là một hướng tiếp cận giàu tiềm năng để tiếp tục nâng cao hiệu quả nhận dạng.

Từ đó, đề tài lựa chọn **TransReID** [6] làm mô hình nền và đề xuất mở rộng theo hướng **visibility-guided patch weighting**. Cụ thể, một nhánh phụ sẽ ước lượng độ tin cậy của từng patch để ưu tiên vùng người nhìn thấy rõ và giảm ảnh hưởng của vùng che khuất hoặc nhiễu nền. Mô hình được huấn luyện bằng ID classification loss, batch hard triplet loss và regularization loss. Phần này sẽ được trình bày chi tiết ở mục Phương pháp đề xuất.

III. Phương pháp đề xuất

Nghiên cứu xây dựng một họ phương pháp dựa trên **TransReID** [6] với mục tiêu khai thác thông tin nhìn thấy ở mức patch nhằm cải thiện chất lượng biểu diễn cho bài toán Person ReID. Giả thuyết là không phải mọi patch đều đóng góp như nhau vào đặc trưng cuối cùng: các patch chứa vùng người ổn định, ít bị che khuất và giàu thông tin nhận dạng cần được ưu tiên hơn so với các patch nền hoặc patch nhiễu. Trên cơ sở đó, nghiên cứu bổ sung vào pipeline của TransReID một nhánh dự đoán trọng số nhìn thấy cho từng patch, sau đó khảo sát nhiều chiến lược tích hợp khác nhau, từ thay thế trực tiếp, hợp nhất tuyến tính cho đến hiệu chỉnh residual có kiểm soát.

A. Tổng quan kiến trúc

Ảnh đầu vào trước hết được chia thành các patch và được đưa qua backbone Transformer của TransReID để thu được tập patch embeddings cùng đặc trưng toàn cục. Trên không gian đặc trưng này, một nhánh phụ được thêm vào nhằm ước lượng mức độ hữu ích của từng patch đối với nhiệm vụ truy hồi. Các trọng số thu được không thay đổi backbone gốc, mà được sử dụng để xây dựng một đặc trưng phụ trợ phản ánh phần thông tin nhìn thấy đáng tin cậy hơn. Tùy theo từng biến thể thực nghiệm, đặc trưng phụ trợ này sẽ được sử dụng theo các cách khác nhau để hình thành đặc trưng truy hồi cuối cùng.

Hình 3 minh họa đồng thời pipeline baseline và pipeline mở rộng để làm rõ vị trí của nhánh *visibility-guided patch weighting* trong kiến trúc tổng thể.

B. Mô hình hóa trọng số nhìn thấy ở mức patch

Ký hiệu $Z = [z_1, z_2, \ldots, z_N]$, với $z_i \in \mathbb{R}^d$, là tập patch embeddings được trích xuất từ backbone. Để lượng hóa tầm quan trọng của từng patch, nghiên cứu bổ sung một đầu dự đoán nhẹ dưới dạng MLP, cho đầu ra là trọng số nhìn thấy w_i:

$$w_i = \sigma(\mathrm{MLP}(z_i)),$$

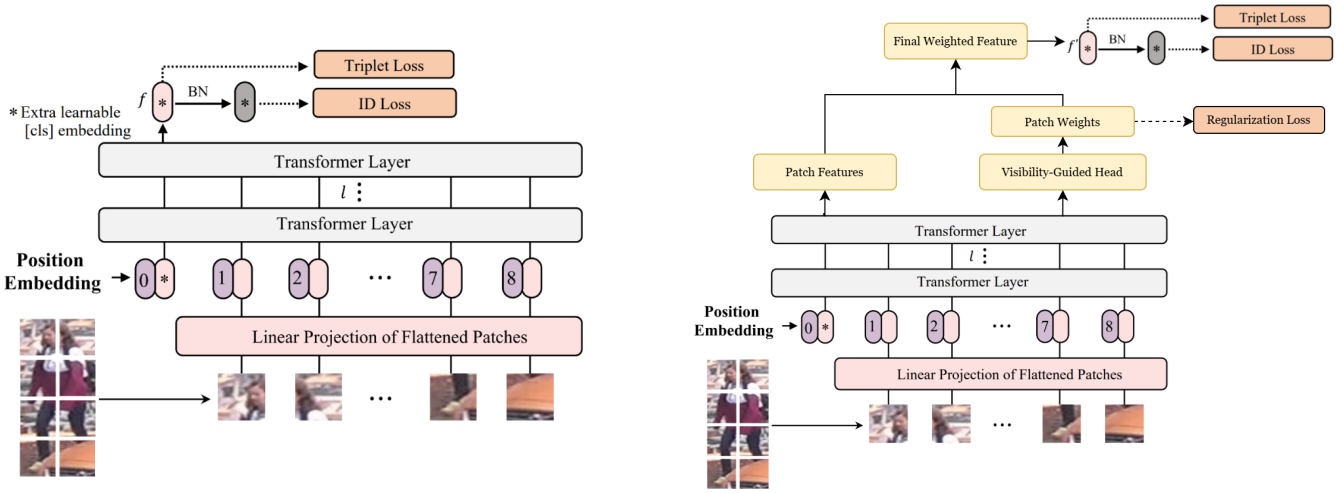

(a) Pipeline baseline

(b) Pipeline đề xuất với visibility-guided patch weighting

Hình 3. So sánh giữa pipeline TransReID gốc và pipeline mở rộng với nhánh ước lượng trọng số theo patch.

trong đó $\sigma(\cdot)$ là hàm sigmoid. Trọng số lớn hơn tương ứng với patch được xem là chứa nhiều thông tin hữu ích hơn cho nhận dạng.

Từ các trọng số này, một đặc trưng phụ trợ dựa trên patch được xây dựng thông qua phép tổng hợp có trọng số:

$$f_{\text{vis}} = \frac{\sum_{i=1}^{N} w_i z_i}{\sum_{i=1}^{N} w_i + \epsilon},$$

trong đó ϵ là hằng số nhỏ nhằm tránh chia cho 0. Cách biểu diễn này cho phép mô hình tập trung mạnh hơn vào các vùng đáng tin cậy, đồng thời giảm ảnh hưởng của các patch bị che khuất hoặc chứa nền.

C. Các chiến lược tích hợp đặc trưng

Thay vì giả định duy nhất một cách kết hợp giữa đặc trưng toàn cục gốc và đặc trưng phụ trợ theo patch, nghiên cứu khảo sát một họ chiến lược tích hợp. Trong biến thể hợp nhất tuyến tính, đặc trưng cuối cùng được xác định bởi

$$f_{\text{final}} = \alpha f_{\text{global}} + (1-\alpha) f_{\text{vis}},$$

với f_{global} là đặc trưng toàn cục của TransReID và $\alpha \in [0,1]$ là hệ số điều khiển mức đóng góp của nhánh mới. Thiết kế này cho phép bảo toàn lợi thế của biểu diễn global gốc mà vẫn khai thác thông tin từ các patch có độ tin cậy cao.

Đối với các cấu hình được huấn luyện từ khởi tạo ImageNet, nghiên cứu còn khảo sát một dạng tích hợp bảo thủ hơn dưới dạng hiệu chỉnh residual:

$$f_{\text{final}} = f_{\text{global}} + \gamma \cdot \big(f_{\text{vis}} - f_{\text{global}}\big),$$

trong đó γ là hệ số cổng học được. Cơ chế này bảo đảm nhánh mới chỉ điều chỉnh biểu diễn gốc một cách từ từ, nhờ đó làm quá trình tối ưu ổn định hơn khi mô hình chưa mang sẵn tri thức ReID chuyên biệt.

Ngoài hai chiến lược chính nêu trên, các thực nghiệm cũng khảo sát những biến thể khác như áp dụng weighting trên các nhánh local của JPM, lọc *foreground-aware top-k patches*, hoặc mở rộng pipeline bằng *token enrichment* và *synthetic occlusion augmentation*. Các biến thể này không thay đổi giả thuyết cơ sở của phương pháp, mà đóng vai trò khảo sát mức độ phù hợp của từng cách tích hợp trong những điều kiện khởi tạo khác nhau.

D. Hợp nhất token theo độ quan sát có xét che khuất (OVTF)

Trong nhóm cấu hình được huấn luyện từ khởi tạo ImageNet, nghiên cứu lựa chọn một biến thể **Occlusion-aware Visibility-guided Token Fusion** (OVTF), nhằm kết hợp cơ chế gán trọng số theo độ quan sát với các thành phần tăng cường biểu diễn và tăng độ bền vững trước che khuất. OVTF vẫn giữ backbone TransReID kết hợp JPM, đồng thời kết hợp bốn thành phần bổ trợ theo một pipeline thống nhất. Trước hết, **visibility-guided patch weighting** gán cho mỗi patch token một trọng số nhìn thấy thông qua một đầu dự đoán nhẹ nhằm lượng hóa mức độ hữu ích của vùng đó đối với truy hồi. Trên cơ sở các trọng số này, cơ chế **dynamic top-k token enrichment** chọn ra nhóm patch có độ tin cậy cao nhất để xây dựng một *visible prototype*, rồi sử dụng prototype đó để tăng cường trở lại cho toàn bộ patch token trước khi tổng hợp đặc trưng. Ở pha suy luận, **JPM fusion** ghép đặc trưng từ nhánh toàn cục với bốn nhánh cục bộ của JPM nhằm đồng thời duy trì thông tin toàn cục và chi tiết vùng. Cuối cùng, **synthetic occlusion augmentation** bổ sung các mẫu che khuất tổng hợp trong quá trình huấn luyện để tăng độ bền vững của mô hình trong điều kiện che khuất và hỗ trợ duy trì tính nhất quán của biểu diễn đặc trưng.

Gọi TopK là tập các patch có trọng số cao nhất, prototype được xây dựng như sau:

$$p = \sum_{i \in \text{TopK}} \alpha_i z_i, \qquad \alpha_i = \frac{\exp(w_i)}{\sum_{j \in \text{TopK}} \exp(w_j)}.$$

Prototype này sau đó được dùng để tăng cường trở lại cho patch embeddings:

$$\tilde{z}_i = z_i + \lambda w_i p.$$

Từ các patch đã được tăng cường, đặc trưng phụ trợ mới được tổng hợp bởi

$$f_{\text{aug}} = \frac{\sum_i w_i \tilde{z}_i}{\sum_i w_i + \epsilon}.$$

Thiết kế trên cho phép nhánh patch-level không chỉ làm nhiệm vụ đánh trọng số, mà còn lan truyền thông tin từ các vùng có độ tin cậy cao đến toàn bộ biểu diễn. Trong pha suy luận, f_{aug} được sử dụng cùng nhánh toàn cục và các nhánh cục bộ JPM để hình thành đặc trưng truy hồi cuối cùng.

Về tối ưu hóa, OVTF kế thừa cơ chế *softmax* + *soft triplet* của TransReID trên nhánh toàn cục và các nhánh JPM. Để tránh phân phối trọng số theo patch bị suy biến, hàm mục tiêu được bổ sung một thành phần điều chuẩn $\mathcal{L}_{reg}$. Khi áp dụng tăng cường che khuất tổng hợp, hàm mục tiêu tiếp tục được mở rộng bởi hai thành phần $\mathcal{L}_{occ}$ và $\mathcal{L}_{cons}$, tương ứng dùng để tăng khả năng nhận dạng trên các mẫu bị che khuất và ràng buộc tính nhất quán giữa ảnh gốc với ảnh che khuất tổng hợp. Khi đó, hàm mất mát tổng quát có thể được viết dưới dạng:

$$\mathcal{L} = \mathcal{L}_{ID}^{JPM} + \mathcal{L}_{tri}^{JPM} + \lambda_{\text{reg}}\mathcal{L}_{reg} + \lambda_{\text{occ}}\mathcal{L}_{occ} + \lambda_{\text{cons}}\mathcal{L}_{cons}.$$

Trong đó, $\mathcal{L}_{reg}$ giúp phân phối trọng số nhìn thấy giữ được tính phân biệt, $\mathcal{L}_{occ}$ tăng khả năng nhận dạng khi một phần cơ thể bị che khuất, còn $\mathcal{L}_{cons}$ ép biểu diễn của cặp (ảnh gốc, ảnh bị che) không lệch nhau quá xa trong không gian đặc trưng. Các siêu tham số chi tiết của cấu hình OVTF được trình bày tại Phụ lục A.

IV. Thiết lập thực nghiệm

A. Bộ dữ liệu và giao thức đánh giá

Các thực nghiệm được triển khai cho bài toán Person ReID trên nền kiến trúc TransReID. Về mặt tham chiếu học thuật, nghiên cứu xem xét hai benchmark chuẩn là **Market-1501** [8] và **DukeMTMC-reID** [9]. Trong phạm vi phần thực nghiệm này, các kết quả định lượng được báo cáo chủ yếu trên **Market-1501**.

Market-1501 gồm 12,936 ảnh huấn luyện của 751 định danh, 3,368 ảnh truy vấn thuộc 750 định danh và 15,913 ảnh gallery thuộc 751 định danh, được thu thập từ 6 camera. Việc đánh giá tuân theo giao thức chuẩn của Person ReID: mô hình được huấn luyện trên tập train và được đánh giá bằng cách truy hồi mẫu đúng trong không gian query–gallery.

B. Chỉ số đánh giá

Hiệu năng được đo bằng hai nhóm chỉ số chuẩn là **Cumulative Matching Characteristics** (CMC) và **mean Average Precision** (mAP). Trong đó, CMC được báo cáo chủ yếu tại các mức **Rank-1**, **Rank-5** và **Rank-10**, còn mAP được dùng làm chỉ số trung tâm khi so sánh các biến thể. Sự lựa chọn này xuất phát từ thực tế rằng các cơ chế gán trọng số, hợp nhất và chọn lọc tác động trực tiếp đến chất lượng sắp hạng toàn cục, nên mAP phản ánh rõ hơn ảnh hưởng của chúng so với một chỉ số Top-1 đơn lẻ.

Các cài đặt chung về backbone, kích thước ảnh, chiến lược tối ưu hóa và giao thức suy luận ở Phụ lục A.

C. Hai thiết lập huấn luyện

Để tránh diễn giải sai đóng góp của phương pháp, các thực nghiệm được tách thành hai thiết lập huấn luyện khác nhau:

1) **Thiết lập fine-tune từ checkpoint ReID**. Ở thiết lập này, mô hình được khởi tạo từ `vit_transreid_market.pth`, tức là một checkpoint TransReID đã đạt hiệu năng cao trên Market-1501. Thiết lập này phù hợp để đánh giá mức độ tương thích giữa phương pháp đề xuất và một baseline ReID đã được huấn luyện trước.
2) **Thiết lập huấn luyện từ khởi tạo ImageNet**. Ở thiết lập này, mô hình được khởi tạo từ `jx_vit_base_p16_224-80ecf9dd.pth`. Vì chưa mang sẵn tri thức ReID chuyên biệt, thiết lập này phản ánh công bằng hơn đóng góp nội tại của kiến trúc đề xuất, dù việc tối ưu hóa cũng khó hơn đáng kể.

Hai thiết lập trên được tách thành hai phần riêng. Thiết lập fine-tune từ checkpoint ReID cho biết liệu phương pháp có thể được tích hợp vào một mô hình ReID đã được huấn luyện trước mà không làm suy giảm hiệu năng hay không. Trong khi đó, thiết lập huấn luyện từ khởi tạo ImageNet thích hợp hơn để đánh giá mức độ tự thân của phương pháp khi mô hình phải học lại biểu diễn ReID từ đầu.

D. Các biến thể được khảo sát

Các biến thể được gọi bằng tên mô tả trực tiếp thay cho các ký hiệu nội bộ. Các cấu hình được nhóm theo hai thiết lập khởi tạo, như tóm tắt trong Bảng I.

Các thực nghiệm được thiết kế để trả lời ba câu hỏi chính: (i) liệu đặc trưng theo patch có thể thay thế trực tiếp biểu diễn toàn cục hay không, (ii) liệu việc tích hợp có kiểm soát ở mức toàn cục hoặc residual có phù hợp hơn không, và (iii) trong điều kiện huấn luyện từ khởi tạo ImageNet, biến thể nào duy trì được sự ổn định hội tụ tốt nhất.

V. Kết quả thực nghiệm

Các kết quả được trình bày theo hai nhóm thiết lập khởi tạo đã nêu ở Mục IV. Bảng II tóm tắt hiệu năng của các biến thể chính trên Market-1501.

A. Kết quả trong thiết lập fine-tune từ checkpoint ReID

Ở thiết lập này, mô hình được khởi tạo từ `vit_transreid_market.pth`; do đó, trọng tâm không nằm ở việc chứng minh nhánh patch có thể tự tạo ra toàn bộ cải thiện, mà ở việc đánh giá liệu phương pháp đề xuất có thể được tích hợp vào một baseline ReID đã được huấn luyện trước mà không làm suy giảm biểu diễn gốc hay không. Các kết quả theo từng mốc đánh giá của nhóm cấu hình này được trình bày trong Bảng III.

1) Hợp nhất toàn cục như cấu hình tham chiếu tốt nhất: Trong toàn bộ nhóm fine-tune, **biến thể hợp nhất toàn cục có trọng số** là cấu hình đạt hiệu năng tuyệt đối cao nhất, với 89.5% mAP và 95.5% Rank-1 tại epoch 120. Kết quả này cho thấy việc giữ nguyên đặc trưng toàn cục của TransReID và chỉ đưa nhánh patch vào như một tín hiệu bổ trợ là một lựa chọn hợp lý. Nói cách khác, đặc trưng toàn cục gốc vẫn đóng vai trò chi phối,

Biến thể	Nội dung khảo sát chính
Thiết lập fine-tune từ checkpoint ReID	
Hợp nhất toàn cục có trọng số	Hợp nhất tuyến tính giữa đặc trưng toàn cục gốc và đặc trưng patch có trọng số với $\alpha = 0.8$.
Cấu hình đối chứng cận baseline	Đặt $\alpha = 1.0$ để triệt giảm đóng góp trực tiếp của nhánh patch vào đầu ra, qua đó tạo một đối chứng gần với baseline.
Gán trọng số ở mức JPM	Áp dụng cơ chế gán trọng số trên các nhánh cục bộ của JPM nhằm khảo sát tích hợp ở mức vùng.
Chọn lọc top-k theo foreground	Giữ lại các patch có foreground score cao nhất trước khi tạo đặc trưng truy hồi nhằm kiểm tra khả năng chọn lọc vùng nhìn thấy đáng tin cậy.
Thiết lập huấn luyện từ khởi tạo ImageNet	
Thay thế trực tiếp đặc trưng toàn cục	Thay trực tiếp đặc trưng toàn cục bằng đặc trưng patch đã được gán trọng số để kiểm tra khả năng thay thế hoàn toàn nhánh toàn cục.
Hiệu chỉnh residual có cổng	Tích hợp nhánh patch dưới dạng hiệu chỉnh residual với cổng học được nhằm bảo toàn vai trò trung tâm của đặc trưng toàn cục trong giai đoạn đầu huấn luyện.
OVTF	Kết hợp gán trọng số theo khả năng quan sát, bổ sung token động, hợp nhất tại JPM và tăng cường che khuất tổng hợp.

Bảng I. Tổng quan các biến thể được khảo sát.

trong khi thông tin patch-level chỉ làm nhiệm vụ tinh chỉnh biểu diễn theo hướng ưu tiên các vùng nhìn thấy đáng tin cậy hơn.

2) Kiểm chứng đóng góp riêng của nhánh patch: Sau khi biến thể hợp nhất toàn cục có trọng số cho kết quả cao, vấn đề phương pháp luận quan trọng là xác định mức đóng góp thực sự của nhánh patch. **Cấu hình đối chứng cận baseline** được xây dựng để trả lời câu hỏi này bằng cách đặt $\alpha = 1.0$, tức là nhánh patch gần như không còn tham gia trực tiếp vào đặc trưng đầu ra. Mặc dù đây chưa phải là baseline sạch hoàn toàn do nhánh gán trọng số vẫn tồn tại như một nhánh phụ, cấu hình này vẫn gần với baseline hơn đáng kể so với biến thể hợp nhất toàn cục có trọng số.

Khoảng cách rất nhỏ giữa hai cấu hình này, chỉ 0.1 điểm mAP và 0.2 điểm Rank-1 ở mốc cuối, cho thấy phần lớn hiệu năng cao trong thiết lập fine-tune nhiều khả năng đến từ chính checkpoint ReID đã được huấn luyện trước. Vì vậy, ở nhóm kết quả này, cho thấy phương pháp đề xuất tương thích tốt với baseline, hơn là khẳng định nhánh patch tự tạo ra một mức cải thiện lớn và độc lập.

3) Các biến thể ở mức cục bộ và mức lọc foreground: **Biến thể gán trọng số ở mức JPM** mở rộng hướng khảo sát bằng cách đưa cơ chế gán trọng số xuống các nhánh cục bộ của JPM, với lập luận rằng hiện tượng che khuất thường diễn ra cục bộ theo từng vùng cơ thể. Tuy nhiên, số liệu hiện có cho thấy cấu hình này không vượt được hợp nhất toàn cục. Tại epoch 40, biến thể này đạt 88.6% mAP và 95.0% Rank-1, ngang về mAP nhưng thấp hơn về Rank-1 so với biến thể hợp nhất toàn cục có trọng số. Điều đó cho thấy việc di chuyển cơ chế gán trọng số xuống mức cục bộ chưa mang lại ưu thế rõ rệt trong phiên bản hiện tại.

Biến thể chọn lọc top-k theo foreground tiếp tục tiến gần hơn với trực giác về khả năng quan sát bằng cách giữ lại nhóm patch có foreground score cao nhất. Đây là một biến thể dễ diễn giải hơn, vì cơ chế chọn lọc không chỉ tái phân bố mức đóng góp mà còn trực tiếp quyết định patch nào được giữ lại. Tuy nhiên, xét trên số liệu, cấu hình này chỉ đạt mức tương đương biến thể hợp nhất toàn cục có trọng số ở mAP và vẫn thấp hơn nhẹ về Rank-1. Như vậy, trong điều kiện fine-tune từ checkpoint ReID, hợp nhất toàn cục vẫn là chiến lược tích hợp hiệu quả và cân bằng nhất.

B. Kết quả trong thiết lập huấn luyện từ khởi tạo ImageNet

Khác với thiết lập trước, toàn bộ mô hình ở đây được huấn luyện từ trọng số tiền huấn luyện ImageNet. Đây là điều kiện khởi tạo khắt khe hơn, vì mô hình chưa sở hữu biểu diễn ReID chuyên biệt ngay từ đầu. Do đó, các kết quả ở nhóm này phản

Biến thể	Mô tả ngắn	mAP (%)	Rank-1 (%)
Thiết lập fine-tune từ checkpoint ReID			
Hợp nhất toàn cục có trọng số	Hợp nhất tuyến tính với $\alpha = 0.8$	**89.5**	**95.5**
Cấu hình đối chứng cận baseline	Đối chứng gần baseline với $\alpha = 1.0$	89.4	95.3
Gán trọng số ở mức JPM	Gán trọng số trê n các nhánh cục bộ của JPM	88.6	95.0
Chọn lọc top-k theo foreground	Chọn lọc các patch có foreground score cao nhất	89.5	95.3
Thiết lập huấn luyện từ khởi tạo ImageNet			
Thay thế trực tiếp đặc trưng toàn cục	Thay trực tiếp đặc trưng toàn cục bằng đặc trưng patch đã được gán trọng số	64.0	81.8
Hiệu chỉnh residual có cổng	Hiệu chỉnh residual với cổng học được; kết quả tốt nhất tại epoch 100	88.4	94.9
OVTF	Gán trọng số theo khả năng quan sát, bổ sung token động, hợp nhất tại JPM và tăng cường che khuất tổng hợp	**89.3**	**95.1**

Bảng II. Tổng hợp các kết quả chính trên Market-1501.

Biến thể	Epoch 20	Epoch 40	Epoch 60	Epoch 80	Epoch 100	Epoch 120
Hợp nhất toàn cục có trọng số	87.3/94.3	88.6/95.2	89.2/95.2	89.3/95.3	89.4/95.4	**89.5/95.5**
Cấu hình đối chứng cận baseline	87.7/94.6	88.5/95.2	89.1/95.0	89.3/95.3	89.4/95.3	89.4/95.2
Gán trọng số ở mức JPM	87.2/94.1	88.6/95.0	–	–	–	–
Chọn lọc top-k theo foreground	87.6/94.7	88.5/95.1	89.1/95.2	89.3/95.4	89.5/95.3	89.5/95.3

Bảng III. Kết quả của các biến thể trong thiết lập fine-tune từ checkpoint ReID theo mAP/Rank-1 (%).

ánh công bằng hơn đóng góp nội tại của phương pháp, đồng thời cho phép quan sát rõ hơn tính ổn định hội tụ của từng chiến lược tích hợp.

1) Biến thể thay thế trực tiếp đặc trưng toàn cục: **Biến thể thay thế trực tiếp đặc trưng toàn cục** là phép thử cực đoan nhất, trong đó đặc trưng toàn cục bị thay thế hoàn toàn bởi đặc trưng patch đã được gán trọng số. Kết quả chỉ đạt 64.0% mAP và 81.8% Rank-1, thấp hơn rất xa so với mọi biến thể còn lại. Bằng chứng này cho thấy đặc trưng patch-level, dù đã được điều chỉnh theo khả năng quan sát, vẫn chưa đủ sức đóng vai trò đại diện chính cho bài toán ReID nếu tách khỏi nhánh toàn cục của TransReID. Do đó, chiến lược thay thế trực tiếp có thể được xem là không phù hợp đối với bài toán này.

2) Biến thể hiệu chỉnh residual có cổng: Sau khi loại bỏ hướng thay thế trực tiếp, nghiên cứu chuyển sang một chiến lược **biến thể hiệu chỉnh residual có cổng**. Ở biến thể này, nhánh patch chỉ đóng vai trò hiệu chỉnh biểu diễn toàn cục thông qua một cổng học được, nhờ đó tác động của nhánh mới được kiểm soát chặt hơn trong giai đoạn đầu huấn luyện. Bảng IV trình bày toàn bộ quá trình hội tụ của biến thể này ở từng mốc epoch.

Biến thể hiệu chỉnh residual có cổng tăng đều từ 84.4% mAP ở epoch 20 lên 88.4% mAP ở epoch 100, sau đó gần như không còn cải thiện ở epoch 120. Xu hướng này cho thấy hiệu chỉnh residual là một cơ chế tích hợp ổn định khi mô hình còn phải học lại toàn bộ biểu diễn ReID từ khởi tạo ImageNet. Đồng thời, việc hiệu năng bão hòa sau epoch 100 cũng cho thấy trong cấu hình hiện tại, kéo dài số epoch đơn thuần khó có khả năng tạo ra thêm lợi ích đáng kể nếu không thay đổi chiến lược tối ưu.

3) Biến thể OVTF: Bên cạnh hai cấu hình trên, nghiên cứu còn khảo sát **OVTF** (*Occlusion-aware Visibility-guided Token Fusion*). Biến thể này kết hợp bốn thành phần đồng thời: gán trọng số theo khả năng quan sát, bổ sung token động (*dynamic token enrichment*), hợp nhất tại JPM và tăng cường che khuất tổng hợp (*synthetic occlusion augmentation*). Mục tiêu của OVTF không chỉ là tích hợp nhánh patch vào đặc trưng cuối, mà còn tăng cường tính bền vững của mô hình trước hiện tượng che khuất và nâng cao khả năng lan truyền thông tin từ các patch có độ tin cậy cao.

Epoch	mAP (%)	Rank-1 (%)	Rank-5 (%)	Rank-10 (%)
20	84.4	92.8	97.8	98.7
40	86.6	94.0	98.1	98.6
60	87.7	94.6	98.3	99.0
80	88.2	94.7	98.1	98.8
100	**88.4**	**94.9**	98.2	99.0
120	88.4	94.8	98.1	99.0

Bảng IV. Diễn biến kết quả của biến thể hiệu chỉnh residual có cổng dưới thiết lập khởi tạo từ ImageNet.

Chi tiết cấu hình của OVTF được trình bày tại Phụ lục A.

Mô hình	mAP (%)	Rank-1 (%)
Baseline TransReID	88.9	**95.2**
OVTF	**89.3**	95.1

Bảng V. So sánh baseline TransReID và OVTF tại epoch 120 dưới thiết lập khởi tạo từ ImageNet.

So với baseline cùng giao thức khởi tạo, OVTF tăng 0.4 điểm mAP trong khi chỉ giảm rất nhẹ 0.1 điểm Rank-1. Điều này cho thấy cấu hình này thực sự cải thiện chất lượng sắp hạng tổng thể, tức là cải thiện phần thứ tự truy hồi ngoài vị trí đầu tiên, dù không làm thay đổi đáng kể top-1 accuracy. Xét trên các số liệu hiện có, OVTF là cấu hình đạt mAP cuối cao nhất trong nhóm huấn luyện với khởi tạo từ ImageNet.

C. Tổng hợp kết quả thực nghiệm

Nhìn chung, chiến lược thay thế trực tiếp đặc trưng toàn cục bằng đặc trưng patch không phù hợp đối với bài toán Person ReID. Ngược lại, các cơ chế tích hợp có kiểm soát cho kết quả khả quan hơn: trong thiết lập fine-tune, biến thể hợp nhất toàn cục có trọng số đạt hiệu năng tuyệt đối cao nhất; trong thiết lập khởi tạo từ ImageNet, biến thể hiệu chỉnh residual có cổng cho thấy quá trình hội tụ ổn định, còn OVTF đạt mAP cuối cao nhất.

VI. Thảo luận

A. Ý nghĩa của hai thiết lập huấn luyện

Việc phân tách hai thiết lập huấn luyện có ý nghĩa quan trọng đối với diễn giải kết quả. Trong thiết lập fine-tune từ checkpoint ReID, hiệu năng cao chủ yếu cho phép kết luận rằng phương pháp có thể được tích hợp vào một baseline đã được huấn luyện trước mà không làm suy giảm đáng kể biểu diễn gốc. Khoảng cách rất nhỏ giữa biến thể hợp nhất toàn cục có trọng số và cấu hình đối chứng cận baseline cũng cho thấy cần thận trọng khi quy toàn bộ mức cải thiện quan sát được cho riêng nhánh patch.

Ngược lại, thiết lập huấn luyện toàn bộ mô hình với khởi tạo từ ImageNet phản ánh trực tiếp hơn năng lực của phương pháp khi mô hình chưa sở hữu tri thức ReID chuyên biệt. Trong bối cảnh này, biến thể hiệu chỉnh residual có cổng và OVTF mang ý nghĩa phương pháp luận lớn hơn. Cấu hình hiệu chỉnh residual có cổng cho thấy một cơ chế tích hợp có khả năng duy trì hội tụ ổn định, trong khi OVTF gợi ý rằng việc kết hợp gán trọng số theo khả năng quan sát, bổ sung token động và tăng cường che khuất có thể cải thiện mAP một cách thực chất so với baseline cùng thiết lập.

B. Ảnh hưởng của chiến lược tích hợp

Các kết quả thực nghiệm cho thấy hiệu quả của nhánh patch-level phụ thuộc mạnh vào cách tích hợp với đặc trưng toàn cục. Khi đặc trưng patch được dùng để thay thế trực tiếp biểu diễn toàn cục, hiệu năng suy giảm nghiêm trọng. Điều này hàm ý rằng trong TransReID, nhánh toàn cục gốc vẫn giữ vai trò trung tâm đối với nhiệm vụ truy hồi và không thể bị thay thế một cách cơ học bởi một đặc trưng patch-level, ngay cả khi đặc trưng này đã được điều chỉnh theo visibility.

Ngược lại, khi nhánh patch được đưa vào dưới dạng tín hiệu bổ trợ hoặc hiệu chỉnh có kiểm soát, mô hình đạt được sự cân bằng tốt hơn giữa ổn định tối ưu và khả năng cải thiện chất lượng biểu diễn. Biến thể hợp nhất toàn cục có trọng số minh họa điều này trong điều kiện fine-tune từ checkpoint ReID, còn biến thể hiệu chỉnh residual có cổng minh họa điều này trong điều kiện khởi tạo từ ImageNet. OVTF tiếp tục đẩy kết quả đi xa hơn bằng cách kết hợp nhiều cơ chế bổ trợ, nhưng đồng thời cũng làm cho việc quy kết đóng góp của từng thành phần riêng lẻ trở nên khó hơn.

C. Lựa chọn cấu hình đại diện cho báo cáo

Không nên quy toàn bộ phần thực nghiệm về một kết quả duy nhất. Nếu xét theo hiệu năng tuyệt đối, **biến thể hợp nhất toàn cục có trọng số** là cấu hình nổi bật nhất, với 89.5% mAP và 95.5% Rank-1 trên Market-1501. Tuy nhiên, khi cần làm rõ đóng góp của phương pháp trong điều kiện đánh giá công bằng hơn, hai kết quả khác cần được nhấn mạnh: **biến thể hiệu chỉnh residual có cổng**, vốn cho thấy quá trình hội tụ ổn định và dễ diễn giải, và **OVTF**, vốn đạt mAP cao nhất trong nhóm khởi tạo từ ImageNet.

Vì vậy, cách trình bày cân bằng nhất cho báo cáo là sử dụng biến thể hợp nhất toàn cục có trọng số như kết quả tốt nhất về mặt hiệu năng tuyệt đối, đồng thời sử dụng biến thể hiệu chỉnh residual có cổng và OVTF để làm rõ hai khía cạnh bổ sung của phương pháp dưới thiết lập khởi tạo từ ImageNet: độ ổn định hội tụ và khả năng cải thiện mAP khi mở rộng kiến trúc.

D. Hạn chế và hướng nghiên cứu tiếp theo

Báo cáo hiện vẫn còn một số hạn chế cần được nêu rõ. Thứ nhất, hầu hết các bằng chứng định lượng mới chỉ được xác nhận trên Market-1501; vì vậy chưa đủ cơ sở để kết luận về khả năng tổng quát hóa liên miền sang DukeMTMC-reID hoặc các benchmark khác. Thứ hai, không phải biến thể nào cũng có log đầy đủ ở mọi mốc đánh giá, nên mức độ so sánh chi tiết giữa các cấu hình vẫn còn không đồng đều. Thứ ba, các kết quả hiện tại chủ yếu dựa trên một số lần chạy đại diện, chưa có đánh giá kiểm tra độ ổn định thống kê.

Trong các bước tiếp theo, hướng mở rộng hợp lý là tái triển khai các cấu hình tốt nhất trên DukeMTMC-reID, chuẩn hóa số lần chạy lặp, đồng thời khảo sát thêm các learning rate scheduler và cơ chế regularization cho thiết lập khởi tạo từ ImageNet. Đặc biệt, việc kết hợp ưu điểm về ổn định của cơ chế hiệu chỉnh residual có cổng với các thành phần tăng cường của OVTF là một hướng nghiên cứu đáng quan tâm, vì đây là hai dòng thực nghiệm đang cho thấy những điểm mạnh bổ sung cho nhau.

VII. Kết luận

Bài báo đã nghiên cứu bài toán *Person Re-identification* trên nền tảng TransReID và đề xuất cơ chế *visibility-guided patch weighting* nhằm ưu tiên các patch chứa thông tin nhận dạng đáng tin cậy hơn trong quá trình truy hồi. Kết quả thực nghiệm trên Market-1501 cho thấy hướng thay thế trực tiếp đặc trưng toàn cục bằng đặc trưng patch là không phù hợp, khi chỉ đạt 64.0% mAP và 81.8% Rank-1 trong thiết lập khởi tạo từ ImageNet. Ngược lại, khi nhánh patch được sử dụng như một tín hiệu bổ trợ có kiểm soát cho đặc trưng toàn cục, mô hình đạt hiệu năng cao hơn và ổn định hơn rõ rệt.

Trong thiết lập fine-tune từ checkpoint ReID, biến thể hợp nhất toàn cục có trọng số đạt kết quả tốt nhất với 89.5% mAP và 95.5% Rank-1, cho thấy phương pháp đề xuất tương thích tốt với baseline TransReID đã được huấn luyện trước. Trong thiết lập huấn luyện từ khởi tạo ImageNet, biến thể hiệu chỉnh residual có cổng đạt 88.4% mAP và 94.9% Rank-1, còn OVTF đạt 89.3% mAP và 95.1% Rank-1, đồng thời cải thiện mAP so với baseline cùng giao thức. Các kết quả này cho thấy thông tin patch-level có giá trị thực tiễn cho Person ReID, nhưng phát huy hiệu quả rõ nhất khi được tích hợp theo hướng bổ trợ hoặc hiệu chỉnh đặc trưng toàn cục, thay vì thay thế hoàn toàn nhánh toàn cục.

Từ đó, có thể kết luận rằng cơ chế gán trọng số patch theo khả năng quan sát là một hướng cải tiến khả thi cho các mô hình ReID dựa trên Transformer. Trong các bước tiếp theo, nghiên cứu có thể được mở rộng bằng cách đánh giá thêm trên DukeMTMC-reID, thực hiện thí nghiệm đa seed để kiểm tra độ ổn định thống kê, và kết hợp ưu điểm của cơ chế hiệu chỉnh residual có cổng với các thành phần tăng cường của OVTF để tiếp tục cải thiện khả năng tổng quát hóa của mô hình.

TÀI LIỆU

[1] Y. Sun, L. Zheng, Y. Yang, Q. Tian, and S. Wang, "Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)," 2018. [Online]. Available: https://arxiv.org/abs/1711.09349

[2] B. Xie, X. Wu, S. Zhang, S. Zhao, and M. Li, "Learning diverse features with part-level resolution for person re-identification," 2020. [Online]. Available: https://arxiv.org/abs/2001.07442

[3] G. Wang, Y. Yuan, X. Chen, J. Li, and X. Zhou, "Learning discriminative features with multiple granularities for person re-identification," in *Proceedings of the 26th ACM international conference on Multimedia*, ser. MM '18. ACM, Oct. 2018, p. 274–282. [Online]. Available: http://dx.doi.org/10.1145/3240508.3240552

[4] K. Zhou, Y. Yang, A. Cavallaro, and T. Xiang, "Omni-scale feature learning for person re-identification," 2019. [Online]. Available: https://arxiv.org/abs/1905.00953

[5] Z. Zhang, C. Lan, W. Zeng, and Z. Chen, "Densely semantically aligned person re-identification," 2019. [Online]. Available: https://arxiv.org/abs/1812.08967

[6] S. He, H. Luo, P. Wang, F. Wang, H. Li, and W. Jiang, "Transreid: Transformer-based object re-identification," 2021. [Online]. Available: https://arxiv.org/abs/2102.04378

[7] W. Chen, X. Xu, J. Jia, H. luo, Y. Wang, F. Wang, R. Jin, and X. Sun, "Beyond appearance: a semantic controllable self-supervised learning framework for human-centric visual tasks," 2023. [Online]. Available: https://arxiv.org/abs/2303.17602

[8] L. Zheng, L. Shen, L. Tian, S. Wang, J. Wang, and Q. Tian, "Scalable person re-identification: A benchmark," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015, pp. 1116–1124. [Online]. Available: https://www.cv-foundation.org/openaccess/content_iccv_2015/papers/Zheng_Scalable_Person_Re-Identification_ICCV_2015_paper.pdf

[9] M. Gou, S. Karanam, W. Liu, O. Camps, and R. J. Radke, "Dukemtmc4reid: A large-scale multi-camera person re-identification dataset," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2017, pp. 10–19. [Online]. Available: https://openaccess.thecvf.com/content_cvpr_2017_workshops/w17/papers/Gou_DukeMTMC4ReID_A_Large-Scale_CVPR_2017_paper.pdf

PHỤ LỤC A
CẤU HÌNH THỰC NGHIỆM CHI TIẾT

A. *Thiết lập cài đặt chung*

Trừ khi có ghi chú khác, các thực nghiệm đều sử dụng backbone `vit_base_patch16_224_TransReID` với cấu hình stride `[12,12]`, `JPM=True` và `SIE_CAMERA=True`. Kích thước ảnh đầu vào cho cả huấn luyện và đánh giá là 256×128. Các thiết lập huấn luyện chung xuất hiện ổn định trong các lần huấn luyện chính gồm: optimizer **SGD**, batch size toàn cục 64, `NUM_INSTANCE=4`, weight decay 10^{-4}, random horizontal flip với xác suất 0.5, random erasing với xác suất 0.5, warm-up tuyến tính trong 10 epoch và đánh giá định kỳ sau mỗi 20 epoch.

Ở pha suy luận, các mô hình được đánh giá với `FEAT_NORM=yes` và đặc trưng trước neck. Riêng các cấu hình sử dụng cơ chế hợp nhất tại JPM hoặc hiệu chỉnh residual vẫn giữ nguyên pipeline truy hồi của TransReID, chỉ thay đổi cách hình thành đặc trưng đầu ra từ thông tin patch-level.

B. *Thiết lập dữ liệu và cấu hình của biến thể OVTF*

Thực nghiệm được thực hiện trên bộ dữ liệu Market-1501 [8]. Theo định nghĩa dataset trong nhánh `train`, bộ dữ liệu được chia theo chuẩn gồm 12,936 ảnh huấn luyện cho 751 định danh, 3,368 ảnh query và 15,913 ảnh gallery.

Để làm rõ mức cải thiện, phần này sử dụng hai cấu hình tại cùng mốc **epoch 120**:

- **Baseline TransReID gốc**: giữ nguyên cấu hình TransReID stride trên Market-1501 với `vit_base_patch16_224_TransReID`, `STRIDE_SIZE=[12,12]`, `SIE_CAMERA=True`, `JPM=True`, đồng thời tắt toàn bộ các thành phần bổ sung gồm `VIS_WEIGHT`, `TOKEN_ENRICH`, `OCC_AUG` và `LOCAL_GROUP`.
- **Biến thể OVTF**: giữ nguyên backbone TransReID stride và bật `VIS_WEIGHT`, `TOKEN_ENRICH` và `OCC_AUG`, trong khi `LOCAL_GROUP` được lược bỏ.

Ở pha suy luận, hệ thống sử dụng `USE_JPM_FUSION=True`, nghĩa là đặc trưng truy hồi cuối cùng được ghép từ nhánh toàn cục và bốn nhánh cục bộ JPM.

Siêu tham số cho huấn luyện:

- optimizer SGD, learning rate ban đầu 0.008.
- batch size 64, với `NUM_INSTANCE=4`.
- weight decay 10^{-4}.
- random horizontal flip với xác suất 0.5.
- random erasing với xác suất 0.5.